

GCerrHMM：面向长读长测序模拟的 GC 感知错误隐马尔可夫模型与可复现评估框架

背景

长读长测序已广泛用于结构变异检测、单倍型组装和复杂基因组研究。当真实真值不可得时，模拟读长被用来检验比对、变异检测和组装流程，因此模拟器的错误过程直接决定下游基准的可信度。现有模拟器多从真实比对中估计全局错误或质量分布，但真实 ONT 错误会随局部序列上下文变化。问题不仅在于模型是否条件化，还在于评估指标是否真的能看见这种条件化。

结果

我们提出 GCerrHMM：一个从真实 ONT 比对训练的状态转移错误 HMM。其转移矩阵按 100 bp 窗口的局部 GC bin 条件化，替换矩阵保持全局；长度感知的 indel 状态用于减少固定长度插入偏置。评估采用预注册的 GC 分层曲线、六基因组方向性面板和覆盖度匹配的人类 chr21 30x 下游面板。

在六个基因组中，GC-aware 模型在四个基因组的两个重复中方向性优于 1-bin 对照；其中 *H. sapiens* chr21 的方向性差异最大 ($B_r = -0.579/-0.091$, $C_r = 0.917/0.861$)。预注册的双物种 × 双判据 gate 为跨物种普遍性设定了判定范围；本研究的重点是可重复的方向性效应及其测量边界，跨物种普遍性由预注册 gate 界定。

不确定性被拆分为两类：between-window bootstrap interval 宽约 1，反映窗口层面的结构性不确定性；read-sampling SD 在 5x/10x/15x 为 0.176/0.194/0.009 (6/3/2 个 subsets)，其中 15x 由两个互补子集估计。复合分布分数用于总结整体分布保真度，GC 条件化由专门的 GC 分层指标评估。chr21 30x 面板中，GCerrHMM 在 alignment identity 上 rank 2、assembly Borda 上 rank 1，支持相对于真实 anchor 的下游一致性。

结论

GCerrHMM 提供了一个可训练、可复现、能显式表达局部 GC 条件化错误状态的模拟框架，并给出了方向性 GC 证据和下游一致性结果。当前证据支持在 GC 结构复杂基因组中的方向性结论；更大规模的预注册 panel 将检验跨物种普遍性。本文的核心方法学结论是，模拟器评估必须让评估指标与被检验的模型性质对齐：包含 GC 条件的指标用于检验 GC 建模，描述性复合分数用于总结整体分布保真度。

图 1-图 9 总览




Figure1_gc_context




Figure2_simulator_landscape




Figure3_context_layers




Figure4_overview_innovation




Figure5_reads_cross_tool




Figure6_alignment




Figure7_variant_calling




Figure8_assembly_phasing




Figure9_ablation

图 1：六基因组局部 GC 结构与真实/模拟 GC-error 曲线。

图 2：2017-2026 长读长模拟器与基准论文景观。

图 3：homopolymer 上下文与评估层级。

图 4：GCerrHMM 整体流程与模型结构。

图 5：reads-level 分布保真度。

图 6：alignment-level 对比。

图 7：variant calling 对比。

图 8：assembly/phasing 与真实 anchor。

图 9：GC-bin、覆盖度和状态空间消融。