

GCerrHMM：面向长读长测序模拟的 GC 感知错误隐马尔可夫模型与可复现评估框架

摘要

背景

长读长测序已广泛用于结构变异检测、单倍型组装和复杂基因组研究。当真实真值不可得时，模拟读长被用来检验比对、变异检测和组装流程，因此模拟器的错误过程直接决定下游基准的可信度。现有模拟器多从真实比对中估计全局错误或质量分布，但真实 ONT 错误会随局部序列上下文变化。问题不仅在于模型是否条件化，还在于评估指标是否真的能看见这种条件化。

结果

我们提出 GCerrHMM：一个从真实 ONT 比对训练的状态转移错误 HMM。其转移矩阵按 100 bp 窗口的局部 GC bin 条件化，替换矩阵保持全局；长度感知的 indel 状态用于减少固定长度插入偏置。评估采用预注册的 GC 分层曲线、六基因组方向性面板和覆盖度匹配的人类 chr21 30x 下游面板。

在六个基因组中，GC-aware 模型在四个基因组的两个重复中方向性优于 1-bin 对照；其中 *H. sapiens* chr21 的方向性差异最大 ($B_r = -0.579/-0.091$, $C_r = 0.917/0.861$)。预注册的双物种 × 双判据 gate 为跨物种普遍性设定了判定范围；本研究的重点是可重复的方向性效应及其测量边界，跨物种普遍性由预注册 gate 界定。

不确定性被拆分为两类：窗口间 bootstrap 区间宽约 1，反映窗口层面的结构性不确定性；read-sampling SD 在 5x/10x/15x 为 0.176/0.194/0.009，分别基于 6/3/2 个 subsets，其中 15x 由两个互补子集估计。复合分布分数用于总结整体分布保真度，GC 条件化由专门的 GC 分层指标评估。chr21 30x 面板中，GCerrHMM 在 alignment identity 上 rank 2、assembly Borda 上 rank 1，支持相对于真实 anchor 的下游一致性。

结论

GCerrHMM 提供了一个可训练、可复现、能显式表达局部 GC 条件化错误状态的模拟框架，并给出了方向性 GC 证据和下游一致性结果。当前证据支持在 GC 结构复杂基因组中的方向性结论；更大规模的预注册 panel 将检验跨物种普遍性。本文的核心方法学结论是，模拟器评估必须让评估指标与被检验的模型性质对齐：包含 GC 条件的指标用于检验 GC 建模，描述性复合分数用于总结整体分布保真度。

背景

长读长测序平台，包括 Oxford Nanopore Technologies (ONT) 和 Pacific Biosciences HiFi，已经成为从头组装、结构变异发现和单倍型分型的重要工具。针对这些平台的每一项方法学进展都需要基准测试，而基准测试要么依赖带有已知真值的真实数据，要么依赖错误过程能够复现真实仪器的模拟读长。模拟器的保真度因此限定了基于这些数据得到的下游结论的有效范围。

常用长读长模拟器，包括 NanoSim [1] 和 PBSim3 [2]，通常从比对后的真实读长中估计错误率或质量分布，再把这些分布均匀地应用到整个基因组。NPBSS [3] 等经验模拟器也优先模拟 read-level 的错误和质量分布。这些方法提供了可靠基线，但其核心模型描述并没有给出局部 GC 条件化的状态转移模型。评估研究同时表明，模拟器的排名取决于评价指标：分布、比对、变异和组装端点可能偏好不同工具 [1-3]。近期工作把模拟范围扩展到宏基因组 [4]、可调信号层生成 [5, 6]、基于 transformer 的信号模型 [7, 8]、面向参数优化的上下文模拟 [9]，以及更严格的长读长基准资源 [10, 11]。一项 2026 年预印本基准比较了六种 ONT 读长模拟器，报告没有任何工具能够同时复现全部 read-level 和错误结构指标，并特别指出 PBSim3 未能捕捉上下文相关的替换率和 homopolymer 长度错误 [11]。因此，GC 条件化不仅需要模型机制，也需要一个能够检验该机制的测量工具。

一个把错误模型条件化到局部 GC 的模拟器很容易提出，真正困难的是测量。如果评估指标看不见 GC 条件化错误，那么任何实验都无法区分 GC 感知模型和 GC 不感知模型，相关文献只会增加一个不可检验的论断。因此，我们把评估框架视为与模型同等重要的贡献：本文中的每一项结论都说明其依赖的测量工具。图 2 概括了近期模拟器设计及其覆盖的建模轴。

本文提出 GCerrHMM：一个从真实长读长比对训练的 error-state HMM，其状态转移结构以局部 GC 含量为条件，并包含长度感知的 indel 编码，用于消除单状态编码中出现的结构性偏置。我们使用两层评估框架（分布保真度和下游任务一致性）在六个基因组和四种模拟器上评估该模型，并对核心 GC 论断采用预注册决策规则。我们报告 GC-aware 模型产生帮助的范围、当前评估工具的精密度边界，以及完成确定性跨物种检验所需的深度预算。图 3 将该研究放入上下文和评估链条中。

结果

从真实比对学习 GC 感知错误模型

GCerrHMM 从真实长读长的 primary alignments 中训练（图 4a）。参考序列被切成 100 bp 窗口，每个窗口分配到一个等宽 GC bin；模型从 CIGAR 路径和替换矩阵中估计 $P(\text{state at } i+1 \mid \text{state at } i, \text{GC bin})$ 。因此，GC 条件化作用于状态转移矩阵；替换矩阵保持全局，而不是 GC 特异。默认状态空间为 M、S、I1、

I2、I3、I4+、D1、D2、D3、D4+，其中 indel 长度由状态编码；简化状态空间把 indel 合并为单个 I 和 D，用作消融控制。1-bin 控制 (K = 1) 使用同一批比对读长、相同 MAPQ 阈值、GC 窗口和读长预算。

模型推导出的每个 GC bin 错误率在存在结构差异的数据中复现了真实数据的定性形状：在具有强局部 GC 异质性的拟南芥中，训练模型在高 GC bin 复现了明显错误峰 (bin 7 为 19.5%)；而 GC 较均匀的大肠杆菌和酿酒酵母曲线较平 (图 4b)。图 4b 是模型推导结果；用于提出该模型的真实与模拟 GC-error 曲线见图 1b。六基因组面板及其数据来源总结在图 4c 和表 1 中。

长度感知 indel 编码消除插入长度上限

如果只使用一个 insertion state，1 bp 插入和 50 bp 插入都会落到同一个状态，I-to-I 转移无法观察，模型会把每个插入都生成为 1 bp。人类 chr21 训练比对的平均插入长度为 3.83 bp，而单状态编码只产生 0.04% 插入碱基，在同一 CIGAR 口径下真实值为 3.78%。run-length 编码 (I1-I3、I4+；D1-D3、D4+，其中 4+ 状态使用重尾长度分布) 把模拟 chr21 的插入碱基比例从 0.04% 提高到 2.54%，平均插入长度从固定 1.00 bp 提高到 2.83 bp，并把总错误率从 6.5% 提高到 8.8%，真实值为 14.5%。在大肠杆菌上的单变量消融中，该编码把 reads-level composite 从 83.5 提高到 87.6，其中 k-mer 子分数提高约 16 分。与真实数据之间的剩余差距主要来自 deletion run length 以及基于比对的训练无法观察到的读长区段。

reads 层保真度

我们在大肠杆菌、酿酒酵母和人类 chr21 的 Level-1 reads-level panel 上比较了 GCerrHMM、NanoSim、PBSim3 (sample 和 errHMM 模式) 和 badread [12] (图 5)，指标包括 read-length 分布、quality-value 直方图、GC 含量分布和 k-mer 频率相关性，并用锁定权重的 composite score 汇总。

composite 上，PBSim3-sample 在大肠杆菌 (92.8) 和 chr21 (89.3) 领先；GCerrHMM 在三个物种上具有竞争力 (87.4/86.7/85.5；在酿酒酵母上与 NanoSim 基本持平，86.7 对 86.8)。PBSim3-errhmm 最低 (72.4/65.8/56.1)，主要受 read-length term (chr21 为 16.0) 和 QV term (45-48) 影响，后者符合预期，因为其占位 Q0 质量字符串无法复现真实 QV 直方图。k-mer term 上 NanoSim 在大肠杆菌领先 (91.1 对 GCerrHMM 82.9)；除 NanoSim 的 chr21 (64.8) 外，所有工具的 GC-content term 都较高 (96-99)。单变量消融显示，长度感知 indel 编码把大肠杆菌 composite 从 83.5 提高到 87.6。

HiFi 跨平台检查完成到端到端 (三个 arm 的 composite 为 64-71，k-mer term 的区间更宽；图 5 右)。用于当前检查的公共 HiFi 大肠杆菌 FASTQ 具有编码受限的质量分布 (Phred-33 均值 80.28)，因此该来源的绝对 QV 一致性只作为指示性结果，不作为典型基准。复合分布分数用于总结整体分布保真度，GC 条件化由专门的 GC 分层指标评估。

比对层

模拟读长使用与对应真实数据相同的 minimap2 和 samtools [13, 14] 流程及设置进行比对 (图 6)。在人类 chr21 上, GCerrHMM 获得最高 mapping rate (88.7%; 工具范围为 85.8-88.7) 和第二高 mean MAPQ (34.1, PBSim3-sample 为 34.3); read-level base identity 由 PBSim3-sample 领先 (96.6%), 随后是 badread (94.8%)、GCerrHMM (91.4%) 和 NanoSim (90.2%)。这一排序通过覆盖度匹配的 delta-to-real panel 转化为相对于真实 anchor 的距离排序。

变异检测

变异层把每个模拟器针对同一合成真值集进行评分 (snp_rate = 0.001, indel_rate = 0.0001, seed 42), 真值集注入所有读长生成所用的 donor reference (图 7)。PBSim3-errhmm 因 Q0 占位质量字符串导致标准 caller 不可评估而省略; 人类 chr21 只出现在 combined-F1 面板中, 因为 PBSim3-sample 没有 SNP/indel 拆分。chr21 的 combined SNP+indel F1 中, PBSim3-sample 领先 (94.9), GCerrHMM (93.7) 和 badread (93.3) 接近, NanoSim 明显较低 (65.6)。在大肠杆菌和酿酒酵母中, 所有工具的 combined F1 为 97.4-99.7, SV spike-in 面板没有工具分离 (69.0-78.0)。

该层按设计没有真实数据端点: 真实 HG002 读长携带 HG002 自身变异, 对合成真值的 F1 为 0.0003, 这是预期结果而不是流程失败。因此, 该层只作为跨工具比较, 并被排除在 delta-to-real 排名之外; 未来工作将把它重新锚定到 GIAB HG002 高置信度调用集。

组装与单倍型分型

两个下游层具有通过同一流程测量的真实数据 anchor: 比对和组装。组装面板使用 Flye [15] 处理 ONT 读长, 使用 hifiasm 处理 HiFi 读长; PBSim3-errhmm 因没有组装运行而省略。组装指标与真实 30x ONT anchor 比较, 汇总见图 8 和表 4。

在覆盖度匹配的 chr21 30x delta-to-real 排名中, GCerrHMM 在 alignment identity (R3) 上排第二 (delta 0.0489), 在 assembly Borda distance (R5) 上排第一 (1.5, 对 badread 的 2.0)。真实 30x ONT anchor 为 48 个 contigs、N50 33.50 Mb、reference identity 79.77%; 该 identity 是未抛光 Flye contigs 通过 asm5 PAF 比对得到的 matched bases/aligned bases, 不是 polished consensus identity, 且所有工具行使用同一指标。

分型使用真实 HG002 HiFi reads 和 WhatsHap [16] (图 8)。真实数据 phased fraction 为 0.9655, 共 179 个 blocks, block N50 为 177,187 bp; 由于没有 bundling phased truth VCF, 未报告 switch

error。spike-in donor 设计为 haploid，不携带 heterozygous sites，因此没有 simulated-read phasing arm。该分型面板是真实数据质量检查，不是跨工具比较。

GC-bin 消融与预注册判定

composite 汇总 read-length、QV、GC-content 和 k-mer terms，用于总结整体分布保真度。GC 论断则在 GC 分层错误曲线上评估：100 bp 等宽窗口的 GC bins，以及每个 bin 内 aligned bases 的错误率；真实和模拟曲线通过 Pearson correlation、Spearman correlation 和 mean absolute deviation 比较。1-bin 模型不能生成 GC 分层错误轮廓，其在有限样本中的相关性反映全局错误水平与真实曲线的对齐，而不是 GC 条件化能力。预注册决策比较 1-bin 对照和 GC-aware 模型，而不是把接近零的 1-bin 相关性当作单独假设。

在 profile-matched bin 消融中 (1、5、10、20 bins，各 3 个 seed)，composite 在拟南芥 (92.6-96.6) 和大肠杆菌 (84.8-87.6) 中均未显示可分离差异 (图 9a)。训练覆盖度和状态空间简化同样没有使 composite 发生分离 (图 9b、9c)。表 3 给出 curve r 和 MAD 的完整结果。

六物种 route panel 比较 route B (1-bin 控制) 和 route C (GC-aware)。在大肠杆菌、酿酒酵母、小鼠 chr19 和人类 chr21 中，GC-aware 模型在两个 replicate 中均方向性优于 1-bin；人类 chr21 的方向性差异最大 ($B\ r = -0.579/-0.091$ ， $C\ r = 0.917/0.861$)。拟南芥和黑腹果蝇呈混合结果。预注册的双物种 gate 为跨物种普遍性设定了判定范围；本研究报告方向性效应和效应量，并把人类 chr21 作为最强的正向支持分析。表 5 给出六物种的 r 值。

噪声被拆分为两类。GC-curve correlation 的 95% between-window bootstrap interval 在 10x、20x 和 30x 分别为 1.01、0.96 和 0.96，反映窗口层面的结构性不确定性，不作为 power statement。read-sampling SD 在 5x、10x 和 15x 分别为 0.176、0.194 和 0.009，基于 6、3 和 2 个 disjoint subsets；15x 由两个互补子集估计，作为深度趋势的补充证据。表 6 汇总该深度网格。

讨论

我们询问把长读长错误模型条件化到局部 GC 含量是否会提高模拟保真度，以及标准评估指标是否能够检测这种改进。我们观察到可测量的 GC 条件化错误结构，并在六种基因组中的四种看到 GC-error 曲线方向性更接近真实数据；人类 chr21 是最强的正向信号。预注册 gate 界定了跨物种结论的范围，本文报告效应量和测量边界，并把更广泛的普遍性检验留给更大规模的预注册 panel。

可检验的边界假设

六基因组面板覆盖 GC 均匀和 GC 高度异质基因组，并为边界假设提供方向性支持：最强正向案例是人类 chr21，而拟南芥和黑腹果蝇表现混合。预注册 gate 界定跨物种结论的范围，人类数据保持为两 replicate 的支持性分析。未来预注册 panel 可以使用更多基因组和独立读长数据，检验 model-implied GC-error amplitude 是否能预测 GC-aware 训练的收益。

评估指标与论断对齐

composite score 并非错误指标，它只是回答不同的问题。由于它的各项均不直接依赖局部 GC 内容，GC 条件化结论应来自 GC 分层错误曲线。本文把 composite 作为整体分布摘要，把带明确区间的 GC 分层曲线作为 GC 论断的主要测量工具。同样的原则也解释了深度分析中的表面矛盾：read-sampling spread 随深度缩小，而 between-window bootstrap 不缩小；只有前者是 power 相关量。混淆两者会从同一数据中得出互相矛盾的结论。

四类测量问题

开发过程中发现并修复了四类会产生“看似合理但错误”结果的测量问题：MAPQ 阈值移除了携带大部分错误信号的读长；单 insertion state 把每个插入限制为 1 bp；缺失 read-length profile 时静默回退到平台默认值；k-mer sub-score 的 replicate spread 超过了它用于排序的 route differences。本文报告这些问题，因为它们决定模拟器基准应如何解读，也因为这些修复使流程从静默降级转为显式报错。

与现有长读长模拟器的关系

NanoSim、PBSim3 和 NPBSS 已经确立了经验或 HMM 长读长模拟的价值 [1-3]。GCerrHMM 保留 alignment-derived、fail-loud 的设计，同时把局部 GC 内容作为显式状态变量，并用预注册分层工具评估该变量。表 7 给出与代表性模拟器的关系。

局限

第一，10-30x 范围内的 GC 条件化效应以方向性证据和效应量报告；预注册 gate 界定跨物种结论的范围，Abstract 中给出了深度预算。第二，Level-1 composite 只测量分布相似性，GC 条件化结论依赖 stratified-error instrument 和受控 bin ablation。第三，k-mer sub-score 在共享 k-mer 交集较小的基因组中区分力有限（黑腹果蝇 $r = 0.12-0.35$ ，对大肠杆菌 $0.86-0.94$ ），replicate spread 可达 16.7 分。第四，variant-calling 层使用合成真值，没有真实数据 anchor；未来工作将使用 GIAB HG002 高置信度调用集重新锚定，6.62x assembly 条件也需要类似处理。第五，由于没有 bundling phased truth，未能报告 phasing switch error。第六，公共 HiFi 大肠杆菌 FASTQ 具有编码受限的质量分布，因此 HiFi QV 一致性仅为指示性结果。

结论

GCerrHMM 是一个可训练的长读长模拟 GC 感知错误模型，包含长度感知 indel 编码、具有竞争力的组成保真度和在 real-anchored layers 上排名前二的下游一致性。其 GC 条件化效应在结构上可测量；本文报告效应量、独立的 sampling 与 structural uncertainties，以及完成确定性跨物种检验所需的深度预算。研究还表明，模拟器基准需要 instrument-claim alignment：一个保真度分数只能检验它自身包含的性质。fail-loud harness、instrument audit 和预注册决策框架随模型发布，使这一标准更容易采用。

方法

框架概览

框架包含四个阶段：(i) 把真实长读长比对到参考序列；(ii) 从比对结果训练 GC-aware error HMM；(iii) 从目标参考序列生成带平台特异 profile 的读长；(iv) 使用 Level-1 分布保真度和 Level-2 下游任务一致性进行两层评估。所有 route 和工具在同一评估层内共享 mapper、caller 和 assembler 设置；每个进入表格或图的模拟数据集都通过 fail-loud gate。

软件版本：minimap2 2.31-r1302 (ONT 使用 map-ont, HiFi 使用 map-hifi)、samtools 1.23.1、bcftools 1.24、Flye 2.9.6-b1802、hifiasm 0.25.0、WhatsHap 2.8、Python 3.11.16、pysam 0.24.1、NumPy 2.4.6、SciPy 1.17.1、Matplotlib 3.11.2 和 Biopython 1.88。

GC 感知 errHMM

模型定义：每个 100 bp 参考窗口的局部 GC 含量被分配到 K 个等宽 bin 之一；模型从 CIGAR 路径和替换矩阵估计 $P(\text{state at } i+1 \mid \text{state at } i, \text{GC bin})$ 。默认状态空间为 M、S、I1、I2、I3、I4+、D1、D2、D3、D4+；简化空间把 indel 合并为单个 I 和 D，并作为消融控制。1-bin 控制 ($K = 1$) 使用相同的 reads、MAPQ 阈值、GC 窗口和 read budget 训练。

长度感知 indel 编码：1、2、3 bp 的 run 分别进入 I1/I2/I3 或 D1/D2/D3；更长 run 共享 I4+/D4+，其长度分布单独学习并呈重尾。chr21 中长度至少 4 bp 的 insertion run 里，35% 为 4 bp，52% 为 5-9 bp，10% 为 10-49 bp，3.5% 至少 50 bp，尾部均值约 241 bp。单 I 状态无法观察 I-to-I transition，因此模型只会生成 1 bp insertion；其数值后果见 Results。

参数估计：使用 pysam 解析真实 long-read BAM 的 primary alignments，根据 CIGAR 和 MD tag 标记 match、substitution、insertion 或 deletion，并按 GC bin 统计 transition。transition probabilities 使用 hierarchical smoothing：pooled transition counts 形成全局 prior，每个 GC bin 向该 prior 平滑。

该过程完全可观察，因此采用基于计数的 maximum likelihood，而不是 Baum-Welch。训练模型保存为 JSON。

MAPQ 策略：panel 模型默认使用 minimum MAPQ 20，人类 chr21 的 30x 模型除外。chr21 是唯一 read pool 小于 20,000-read cap 的物种：8,189 条 primary reads 中 58% 低于 MAPQ 20；使用默认阈值只保留 3,438 条，并改变 learned error spectrum (event rate 0.0459 对 MAPQ 0 的 0.0713)。因此 chr21 模型使用 minimum MAPQ 0；其他物种保留 MAPQ 20，因为其 read pools 在 cap 处基本不受阈值影响。hierarchical smoothing 使用 prior strength 10.0 和 pseudocount 1.0。

读长生成：每个参考位置读取 GC bin，从对应 transition row 采样下一状态；substitution 使用 learned nucleotide matrix，indel、read length 和 quality values 由 route-specific model 和 profile 生成。生成器在父进程中采样 read layouts，为每个 read 指定 deterministic seed，并在固定大小 chunk 中由最多 16 个 worker 生成，因此 FASTQ 与 worker count 无关。

参考基因组和真实数据

六个参考面板覆盖大肠杆菌、酿酒酵母、拟南芥、黑腹果蝇、人类 chr21 (HG002) 和小鼠 chr19，从 GC 均匀到 GC 高度异质。ONT accessions 记录在 repository configuration 中；HiFi 来源单独记录 accession、文件大小和 checksum。表 1 给出参考和 ONT accessions。训练使用真实 alignment panels，评估使用匹配的 simulated FASTQ，模拟数据不参与模型训练。

模拟设计

内部 route 包括：sample route (经验采样基线)、1-bin route ($K = 1$ 的 GC 不感知控制) 和 GC-aware route (完整 GC 条件化模型)。replicate 只改变随机 seed。跨工具 panel 比较 GCerrHMM、NanoSim、PBSim3 (sample 和 errHMM 模式) 和 badread；所有工具使用相同 real-read profile 和 target coverage，并使用相同 truth-variant reference。

外部 cross-tool panel 每个工具-物种组合使用一个模拟 replicate；内部 B/C panel 使用两个 replicate；GC-bin ablation 在 10x 下使用三个 seed。PBSim3-errhmm 保留在 reads 和 alignment panels，因为这两类指标不依赖 quality values；variant panel 因 Q0 占位质量而省略；assembly panel 因没有运行组装而省略。PBSim3-sample 出现在所有适用面板；chr21 没有 SNP/indel 拆分，因此只出现在 combined-F1 panel。

Level-1 评估

Level-1 比较真实和模拟 FASTQ 的 read-length、QV、GC 和 k-mer 分布。composite 使用锁定权重 (read_length 0.15、QV 0.20、GC 0.25、k-mer 0.15) , 并在可用项上重新归一化; 报告 panel 中 error-rate term 关闭。read length 和 QV 因共享 real-read profile 而在构造上匹配, 主要用于验证 profile 应用, 而不是区分模拟器能力。四项均不直接依赖局部 GC 内容, 因此 composite 作为描述性摘要, 不用于 GC claim。

GC claim 使用 aligned instrument: 100 bp 等宽 per-window GC bins, 以及每个 bin 内 aligned bases 的 error rate, soft-clipped bases 排除。真实和模拟集合使用同一 mapper; 模拟 per-bin profile 与真实 profile 通过 Pearson 和 Spearman correlation 以及 mean absolute deviation 比较。1-bin 模型不能生成 GC 分层 profile, 其有限样本 correlation 反映 global error level 与真实曲线的对齐, 不反映 GC 条件化能力。k-mer term 在每侧 top-10,000 k-mer maps 的交集上计算 frequency-vector Pearson correlation ($k = 21$) ; 样本量从 250 增加到 1000 reads/side, 并使用 paired bootstrap。

Level-2 评估

比对: 模拟和真实 reads 使用同一 mapper 和设置; 汇总 mapping rate、MAPQ、CIGAR-derived error rates 和 read-level identity。变异检测: normalized VCFs 使用相同 caller 和 filters 与 truth VCF 比较; 由于 truth set 是合成并注入共享 donor reference, 该层作为 cross-tool comparison, 并从 delta-to-real 中排除。组装: HiFi 使用 hifiasm, ONT 使用 Flye。分型: 有 phased truth 时使用 WhatsHap; HG002 panel 没有 phased truth, 因此只报告 phased fraction 和 block statistics。delta-to-real rankings 只在具有真实 anchor 且流程一致的层计算 (alignment 和 assembly) 。

消融

GC-bin granularity: K 取 {1, 5, 10, 20}, 使用 profile-matched training 和三个 seed, 在 composite 和 GC-stratified instrument 上评估; 预注册 gate 界定跨物种 significance claim 的范围。训练覆盖度: 在 coverage grid 上的匹配 panel, 用 composite 评估。文中的效应以 effect sizes 和 measurement budget 报告。

统计和可复现性

replicate 只改变随机 seed。paired bootstrap intervals 对 read indices 重采样一次, 并在两个 route 中复用。GC-fidelity instrument 的不确定性分解为 read-sampling 成分 (pooled 30x simulation 的 disjoint subsamples) 和 between-window bootstrap 成分; 只有前者作为 power statement。所有进入表格或图的模拟都通过 fail-loud gate: entry check 要求 read-length 和 quality profile; exit check 以 10% 容差重新计算 produced read count、total bases 和 mean read length; 违反即中止。预期无人

值守的 job 会被监控并在静默失败时重启。repository 提供 `reproduce.sh --gc-demo` (重训练和匹配模拟) 和 `--framework-figures` (评估表和 figure suite) 。

声明

伦理批准和参与同意：不适用。

发表同意：不适用。

数据和材料可用性：代码与冻结结果可通过 GitHub repository `https://github.com/zbyyyxiaoman/GCerrHMM` 获取，版本稳定的 Zenodo concept DOI 为 `10.5281/zenodo.23034361`；公共 accessions 见表 1。

竞争利益：待作者提供。

资助：待作者提供基金编号；如无基金，将声明“无”。

作者贡献：待作者按 CRediT 提供。

致谢：待作者提供；如无，将声明“不适用”。

参考文献

1. Yang C, Chu J, Warren RL, Birol I. NanoSim: nanopore sequence read simulator based on statistical characterization. *GigaScience*. 2017;6(4):1-6. doi:10.1093/gigascience/gix010.
2. Ono Y, Hamada M, Asai K. PBSIM3: a simulator for all types of PacBio and ONT long reads. *NAR Genomics and Bioinformatics*. 2022;4(4):lqac092. doi:10.1093/nargab/lqac092.
3. Wei ZG, Zhang SW. NPBSS: a new PacBio sequencing simulator for generating the continuous long reads with an empirical model. *BMC Bioinformatics*. 2018;19:177. doi:10.1186/s12859-018-2208-0.
4. Yang C, Lo T, Nip KM, Hafezqorani S, Warren RL, Birol I. Characterization and simulation of metagenomic nanopore sequencing data with Meta-NanoSim. *GigaScience*. 2023;12:giad013. doi:10.1093/gigascience/giad013.
5. Gamaarachchi H, Ferguson JM, Samarakoon H, Liyanage K, Deveson IW. Simulation of nanopore sequencing signal data with tunable parameters. *Genome Research*. 2024;34(5):778-783. doi:10.1101/gr.278730.123.

6. Munro R, Wibowo S, Payne A, Loose M. Icarust, a real-time simulator for Oxford Nanopore adaptive sampling. *Bioinformatics*. 2024;40(4):btae141. doi:10.1093/bioinformatics/btae141.
7. Beslic D, Kucklick M, Engelmann S, Fuchs S, Renard BY, Körber N. End-to-end simulation of nanopore sequencing signals with feed-forward transformers. *Bioinformatics*. 2024;41(1):btae744. doi:10.1093/bioinformatics/btae744.
8. Xie S, Ding L, Liu L, Ong YS, Li J, Zhu Z. NanoSimFormer: an end-to-end transformer-based nanopore signal simulator with basecaller guidance. *Bioinformatics*. 2026;42(6):btag402. doi:10.1093/bioinformatics/btag402.
9. Hu J, Fang D, Jin X, Yang C. Context-aware simulation enables systematic optimization of long-read mapping parameters. *GigaScience*. 2026;15:giag079. doi:10.1093/gigascience/giag079.
10. Kronenberg Z, Nolan C, Porubsky D, et al. The Platinum Pedigree: a long-read benchmark for genetic variants. *Nature Methods*. 2025;22(8):1669-1676. doi:10.1038/s41592-025-02750-y.
11. Taouk ML, Ingle DJ, Wick RR. Benchmarking long-read simulators against Oxford Nanopore whole-genome sequencing data. *bioRxiv*. 2026. doi:10.64898/2026.05.06.723380. Preprint.
12. Badread: a read simulator for long reads. <https://github.com/rrwick/Badread>. Accessed 29 September 2026.
13. Li H. Minimap2: pairwise alignment for nucleotide sequences. *Bioinformatics*. 2018;34(18):3094-3100. doi:10.1093/bioinformatics/bty191.
14. Li H, Handsaker B, Wysoker A, et al. The Sequence Alignment/Map format and SAMtools. *Bioinformatics*. 2009;25(16):2078-2079. doi:10.1093/bioinformatics/btp352.
15. Kolmogorov M, Yuan J, Lin Y, Pevzner PA. Assembly of long, error-prone reads using repeat graphs. *Nature Biotechnology*. 2019;37(5):540-546. doi:10.1038/s41587-019-0072-8.
16. Patterson M, Marschall T, Pisanti N, et al. WhatsHap: weighted haplotype assembly for future-generation sequencing reads. *Journal of Computational Biology*. 2015;22(6):498-509. doi:10.1089/cmb.2014.0157.

图注

图 1：六基因组面板的局部 GC 结构，以及大肠杆菌真实与模拟 GC-error 曲线的示例。图 1a 使用分析的参考面板；图 1b 使用项目 GC-error 曲线。不展示推断性误差棒。

图 2：近期长读长模拟和基准论文景观。图 2a 显示 2017-2026 年的代表性工作；图 2b 根据被引论文的核心模型描述，对主要模型特征进行定性总结。yes、partial 和 - 表示主设计元素、辅助组件或非主模型轴，不代表性能评分。

图 3：上下文依赖与评估层级。图 3a 使用项目真实大肠杆菌 ONT panel，显示删除率随 homopolymer 长度的变化；图 3b 是对近期文献所覆盖建模和评估层级的定性综合。该图用于说明 metric-aligned evaluation，不对工具进行排名。

图 4：GCerrHMM 整体流程和模型结构。图 4a 是从 ONT 或 PacBio HiFi BAM 到 CIGAR 错误状态学习、GC 条件化转移建模、匹配模拟和四层评估的双平台流程；图 4b 是代表性基因组的 model-implied GC bin 错误状态；图 4c 是参考 accession、基因组大小、GC 含量、1-kb GC heterogeneity 和真实 ONT run accession。n = 六个参考面板；不展示误差棒。

图 5：GCerrHMM、NanoSim、PBSim3-sample、PBSim3-errhmm 和 badread 的匹配数据比较，包括 read-length、QV、GC 和 k-mer 相似性。当前测量 facet 为 ONT；HiFi facet 在完成相同训练、模拟和匹配采样评估后生成。PBSim3-errhmm 保留在 reads 统计中，因为这些指标不依赖其 Q0 质量字符串。n = 每个物种和工具一个匹配模拟；热图为点估计，不展示误差棒。

图 6：公共 minimap2 和 samtools 流程后的 mapping rate、mean MAPQ 和 base-level identity。PBSim3-errhmm 保留，因为其 mapping statistics 有效，但 Q0 占位质量使标准 variant calling 不可评估。人类 chr21 行使用覆盖度匹配的 30x panel。n = 每个物种和工具一个匹配 alignment run；热图为点估计。

图 7：针对同一 truth VCF 的大肠杆菌、酿酒酵母和人类 chr21 combined SNP/indel F1，以及具有完整测量的两个物种的 SNP-only、indel-only 和 SV spike-in F1。人类 chr21 行使用覆盖度匹配的 30x panel；该层作为 cross-tool comparison，并从 delta-to-real 中排除。PBSim3-errhmm 因 Q0 占位质量而省略；PBSim3-sample 没有 SNP/indel 拆分，因此 chr21 只出现在 combined-F1 panel。n = 每个物种和工具一个匹配 caller run；SV 值汇总四种 spike-in 设计，置信区间见附表。

图 8：测量面板的 assembly N50 和 reference identity，以及 phasing 状态。HiFi 使用 hifiasm，ONT 使用 Flye，diploid phasing 使用 WhatsHap 对照 phased truth VCF。历史 raven 值不重新标记为 hifiasm 或 Flye。人类 chr21 行使用覆盖度匹配的 30x panel；N50 色阶覆盖 0-40 Mb，以保留真实

anchor 和模拟范围。n = 每个物种和工具一个 Flye assembly，再加一个真实 30x ONT anchor；不展示误差棒。

图 9：消融和稳健性。图 9a 是大肠杆菌和拟南芥的 profile-matched GC-bin 消融（三个 seed）；图 9b 是 1x-30x 训练覆盖度消融；图 9c 是完整与简化状态空间模型。误差棒为 mean $\pm$ SD；n = 每个条件三个 seed。

主要数据表

表 1：六物种参考面板和 ONT accession

物种	RefSeq assembly	大小 (Mb)	GC (%)	1-kb GC heterogeneity (SD)	ONT run
大肠杆菌	GCF_000005845.2	4.6	50.8	4.8	SRR39619343
酿酒酵母	GCF_000146045.2	12.2	38.1	3.8	SRR39791672
拟南芥	GCF_000001735.2	119.7	36.1	5.5	ERR5716408
黑腹果蝇	GCF_000001215.4	143.7	42.0	6.3	SRR22071686
小鼠 chr19	GCF_000001635.27	61.4	42.7	5.7	SRR14685232
人类 chr21	GCF_000001405.40	51.5	41.2	8.2	ERR13491992

表 2：chr21 30x delta-to-real 面板

真实 anchor：base identity 0.8655；assembly 48 contigs、N50 33.50 Mb、reference identity 0.7977。

工具	R3 identity (距离)	R5 identity	R5 N50 (Mb)	R5 Borda	R3 rank	R5 rank
GCerrHMM	0.9144 (0.0489)	0.9086	25.04	1.50	2.0	1.0
NanoSim	0.9020 (0.0365)	0.9166	10.04	3.00	1.0	3.0
PBSim3-sample	0.9657 (0.1002)	0.9460	21.48	3.50	4.0	4.0
badread	0.9478 (0.0823)	0.9212	33.74	2.00	3.0	2.0

R3 为真实 30x ONT anchor base identity 的绝对距离；R5 Borda 为 identity 绝对差排名和 $|\log_2(N50_tool/N50_real)|$ 排名的平均值。R4 variant 层无真实 anchor，因此不参与 delta-to-real 排名。

表 3：profile-matched GC-bin 消融

物种	GC bins	Curve r, mean (SD)	MAD pp, mean (SD)
大肠杆菌	1	0.077 (0.334)	0.255 (0.006)
大肠杆菌	5	-0.080 (0.571)	0.252 (0.004)
大肠杆菌	10	0.233 (0.504)	0.258 (0.003)
大肠杆菌	20	0.576 (0.184)	0.266 (0.007)
拟南芥	1	0.779 (0.062)	4.204 (0.010)
拟南芥	5	0.960 (0.011)	4.212 (0.039)
拟南芥	10	0.970 (0.002)	4.475 (0.015)
拟南芥	20	0.981 (0.004)	4.398 (0.039)

表 4: read-sampling 深度网格

深度	Disjoint subsets	Mean r	SD across subsets
5x	6	0.047	0.176
10x	3	0.139	0.194
15x	2	0.008	0.009

15x 由两个互补子集估计，作为深度趋势的补充证据；不同深度的 subset 数量和每个 subset 的覆盖度不同，SD 不直接跨深度比较。

表 5: 六物种 route B/C 方向性面板

物种	B (1-bin) r1 / r2	C (GC-aware) r1 / r2	方向
大肠杆菌	-0.738 / 0.505	0.458 / 0.589	两个 replicate 均为 C > B
酿酒酵母	0.230 / 0.174	0.471 / 0.535	两个 replicate 均为 C > B
拟南芥	0.325 / 0.902	0.947 / 0.862	混合
黑腹果蝇	-0.778 / -0.756	-0.882 / -0.570	混合
小鼠 chr19	0.460 / 0.650	0.922 / 0.794	两个 replicate 均为 C > B
人类 chr21	-0.579 / -0.091	0.917 / 0.861	两个 replicate 均为 C > B

表 6: 与代表性长读长模拟器的关系

工具	主要模型	局部上下文	评估重点	与本研究的关系
NanoSim [1]	alignment-derived error profiles 和 Markov chain	read/alignment profile	read composition 和 alignment	外部基线；没有显式 GC 条件化转移状态
PBSim3 [2]	HMM error model	platform/error profile	quality 和 error profiles	外部基线；支持多平台
NPBSS [3]	empirical error 和 quality model	read/error profile	error-QV 和 assembly	经验模拟方法学对照
GCerrHMM	GC-aware error HMM, 含 run-length indel states	100 bp reference window 和 GC bin	GC-curve fidelity 和 delta-to-real	显式建模 GC 相关错误结构

附加文件

附加文件 1: Additional_file_1_species_panel.xlsx, XLSX; 物种面板和来源 accession。

附加文件 2: Additional_file_2_level1_sub_scores.xlsx, XLSX; 分物种 Level-1 子分数和 HiFi 跨平台分数。

附加文件 3: Additional_file_3_gc_bin_ablation.xlsx, XLSX; GC-bin 消融完整表。

附加文件 4: Additional_file_4_delta_to_real.xlsx, XLSX; delta-to-real 逐工具表和 30x panel。

附加文件 5: Additional_file_5_instrument_audit.pdf, PDF/DOCX; 四类测量问题、症状和修复。

附加文件 6: Additional_file_6_uncertainty_layers.pdf, PDF/DOCX; GC 保真度测量的 sampling 和 structural uncertainty。

附加文件 7: Additional_file_7_hifi_crossplatform_note.pdf, PDF/DOCX; HiFi 跨平台链条和 QV 编码限制。




Figure1_gc_context




Figure2_simulator_landscape




Figure3_context_layers




Figure4_overview_innovation




Figure5_reads_cross_tool




Figure6_alignment




Figure7_variant_calling




Figure8_assembly_phasing




Figure9_ablation